Proyecto 1: Analizador Léxico

I. DESCRIPCIÓN

En este proyecto, Ud deberá desarrollar un *scanner* para el Lenguaje C. Toda la programación debe realizarse en C sobre Linux, usando la herramienta flex. La salida es una presentación Beamer que será desplegada automáticamente desde su programa. No se pueden cambiar las especificaciones de este documento.

II. EJECUCIÓN

El programa se invocará desde la línea de comando de una consola. Recibirá como argumento el nombre del archivo fuente a ser procesado, junto con cualquier opción al estilo tradicional de UNIX/Linux.

III. PREPROCESO

Antes de empezar el análisis léxico, su programa debe manejar una forma básica de preproceso que genera un nuevo archivo temporal con el fuente después del preproceso. Este archivo es la verdadera entrada al *scanner*.

Se siguen las mismas reglas sintácticas del preprocesador de C (el cual es muy estricto y limitado - afortunadamente). Nos limitaremos a las siguientes directivas:

- #include: permite incluir un archivo de texto como parte del fuente. Dicho archivo siempre reside en el directorio actual. Nótese que este archivo puede contener de nuevo directivas de preproceso que deben ser tomadas en cuenta.
- #define: asocia un nombre (con las mismas reglas de los nombres de variables) con una hilera de texto formada por el resto de los carácteres de la línea del archivo. Cualquier aparición del mismo nombre en el resto del fuente debe ser reemplazada por la hilera asociada. Esta hilera podría contener otros símbolos definidos con #define que deben ser expandidos. Para este proyecto no se manejarán macros con parámetros.

Trabajo extra opcional 1: Manejar macros con parámetros

IV. SCANNER

Usando la herramienta flex, es relativamente fácil generar la mayor parte (sino todo) del código de un analizador léxico o *scanner*¹. En este caso, se pide que Ud. escriba un *scanner* para el lenguaje C completo, tal y como está descrito en la documentación oficial del lenguaje. Entre otras cosas, se deberá obtener una función semejante al Get_Token() estudiado en clases, la que, al ser invocada, regresará el siguiente *token*

del fuente procesado, en alguna estructura de datos apropiada que tenga cosas como: código de *token*, puntero al lexema, valor numérico del lexema, etc.

Se recomienda que estructure su programa de tal manera que Get_Token() sea independiente del resto del código para posibles usos en proyectos futuros.

La entrada a esta parte de su programa es el archivo de texto temporal generado por el preprocesador, que presumiblemente es un programa escrito en C, pero en realidad podría ser cualquier archivo, ya sea de texto o binario.

V. SALIDA

Su programa debe producir una presentación Beamer con los resultados descritos más abajo. Esto implica, en primer lugar, generar un programa fuente de LATEX. Internamente, se ejecutará el comando pdflatex para que procese dicho archivo y que genere un PDF, el cual será desplegado de inmediato (posiblemente usando el comando evince) en modo presentación (full screen).

Se espera una presentación Beamer de gran calidad (con tablas, colores, dibujos, imágenes, gráficos, etc.) que incluirá como mínimo lo siguiente:

- Portada identificando al grupo de trabajo, al semestre del curso, y al proyecto.
- Una explicación general del proceso de scanning y de la herramienta flex.
- Múltiples slides con el programa fuente que le entró a la fase de scanning (i.e., después del preproceso), pero con una clara distinción de cada lexema. Utilice distintos tipos de letra, pesos, inclinaciones y combinaciones de colores (juegos de foreground y background) para cada categoría léxica. Los errores léxicos deben ser reportados de la misma manera. Ponga una cantidad razonable de líneas del fuente original en cada slide.
- Histograma de las cantidades de cada tipo de token encontrados en el fuente. Para esto, podrían preparar internamente un archivo de datos e invocar al comando gnuplot desde su programa o usar el package pgfplots de LATEX.

Trabajo extra opcional 2: generar un *slide* con un gráfico de pastel de las categorías léxicas encontradas (misma información que el histograma). Se debe usar indispensablemente el package pafplots de LATEX.

VI. REQUISITOS INDISPENSABLES

La ausencia de uno solo de los siguientes requisitos vuelve al proyecto "no revisable" y recibe un 0 de calificación inmediata:

¹Considere también el uso de flex para su preprocesador.

- Todo el código debe estar escrito en C
- El proyecto debe compilar y ejecutar en Linux
- El proyecto se debe presentar en una **máquina física** que levante en Linux (puede ser dual)

VII. FECHA DE ENTREGA

Demostraciones a las 11:30am del Martes 19 de Setiembre. Mande además un .tgz con todo lo necesario (fuentes, makefile, readme, etc.) a torresrojas.cursos@gmail.com. Ponga como subject: COMPILADORES - Proyecto 1 - Fulano - Mengano - etc., donde Fulano, Mengano, etc. son los miembros del grupo.

Mucha suerte...